

# Superpixel: entendimento e aplicação

Introdução à Visão Computacional

Professor Lucas Silveira Kupssinskü

Bento Bastian, Bernardo Zamin e Luciano Farias

# Agenda

- Contextualização
- Sobre o Superpixel
- O Algoritmo SLIC
- Aplicações e Desafios
- Conclusões
- Demo

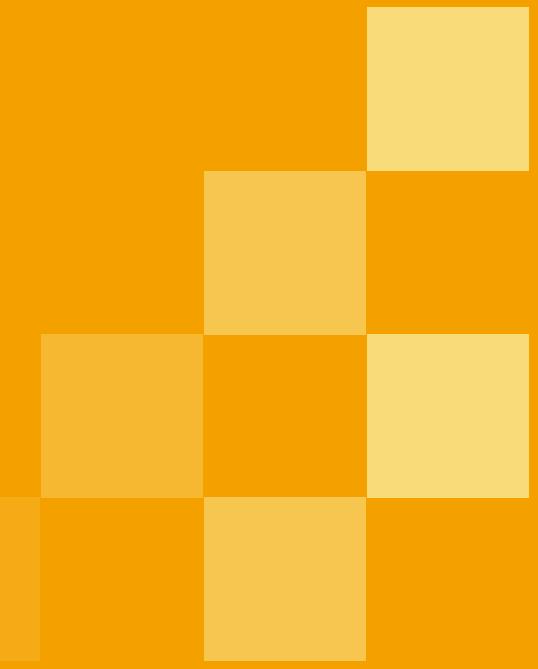
# Contextualização

A técnica de Superpixels surge como um conceito poderoso dentro do campo da visão computacional, especialmente no que tange à eficiência e eficácia no processamento de imagens. Tradicionalmente, a análise de imagens é realizada em nível de pixel, o que pode ser intensivo em termos computacionais devido à alta dimensionalidade dos dados.

Os superpixels reduzem essa complexidade ao agrupar pixels contíguos que compartilham características semelhantes, como cor ou textura, formando unidades coerentes que são mais significativas e informativas do que os pixels isoladamente.

Essa abordagem não apenas melhora a performance de algoritmos subsequentes, reduzindo o número de elementos a serem processados, mas também preserva detalhes essenciais de bordas e contornos, fundamentais para a segmentação de imagens e reconhecimento de padrões.

Ao incorporar superpixels, métodos de visão computacional ganham não só em eficiência, mas também em precisão, facilitando a interpretação e manipulação de imagens em um nível que aproxima o entendimento humano sobre o ambiente visual.



# Sobre o Superpixel

O que há de tão super assim?

# Super pagamento em dólar?



ZipRecruiter

<https://www.ziprecruiter.com> › Jobs › Data-Annotation

\$17-\$36/hr Data Annotation Jobs (NOW HIRING) Jul 2024

Browse 184 **DATA ANNOTATION** jobs (\$17-\$36/hr) from companies with openings that are hiring now. Find job postings near you and 1-click apply!

Remote · Ontario · Online Data Annotation Jobs · Data Annotation Technician



DataAnnotation.tech

<https://www.dataannotation.tech> :

**DataAnnotation.tech | Your New Remote Job**

Apply to **DataAnnotation** to train AI for on-demand work from home. Choose from diverse tasks that suit your skills, with flexible hours and pay starting at ...

About · FAQ | DataAnnotation.tech · Blog · My Digital Nomad Life with...

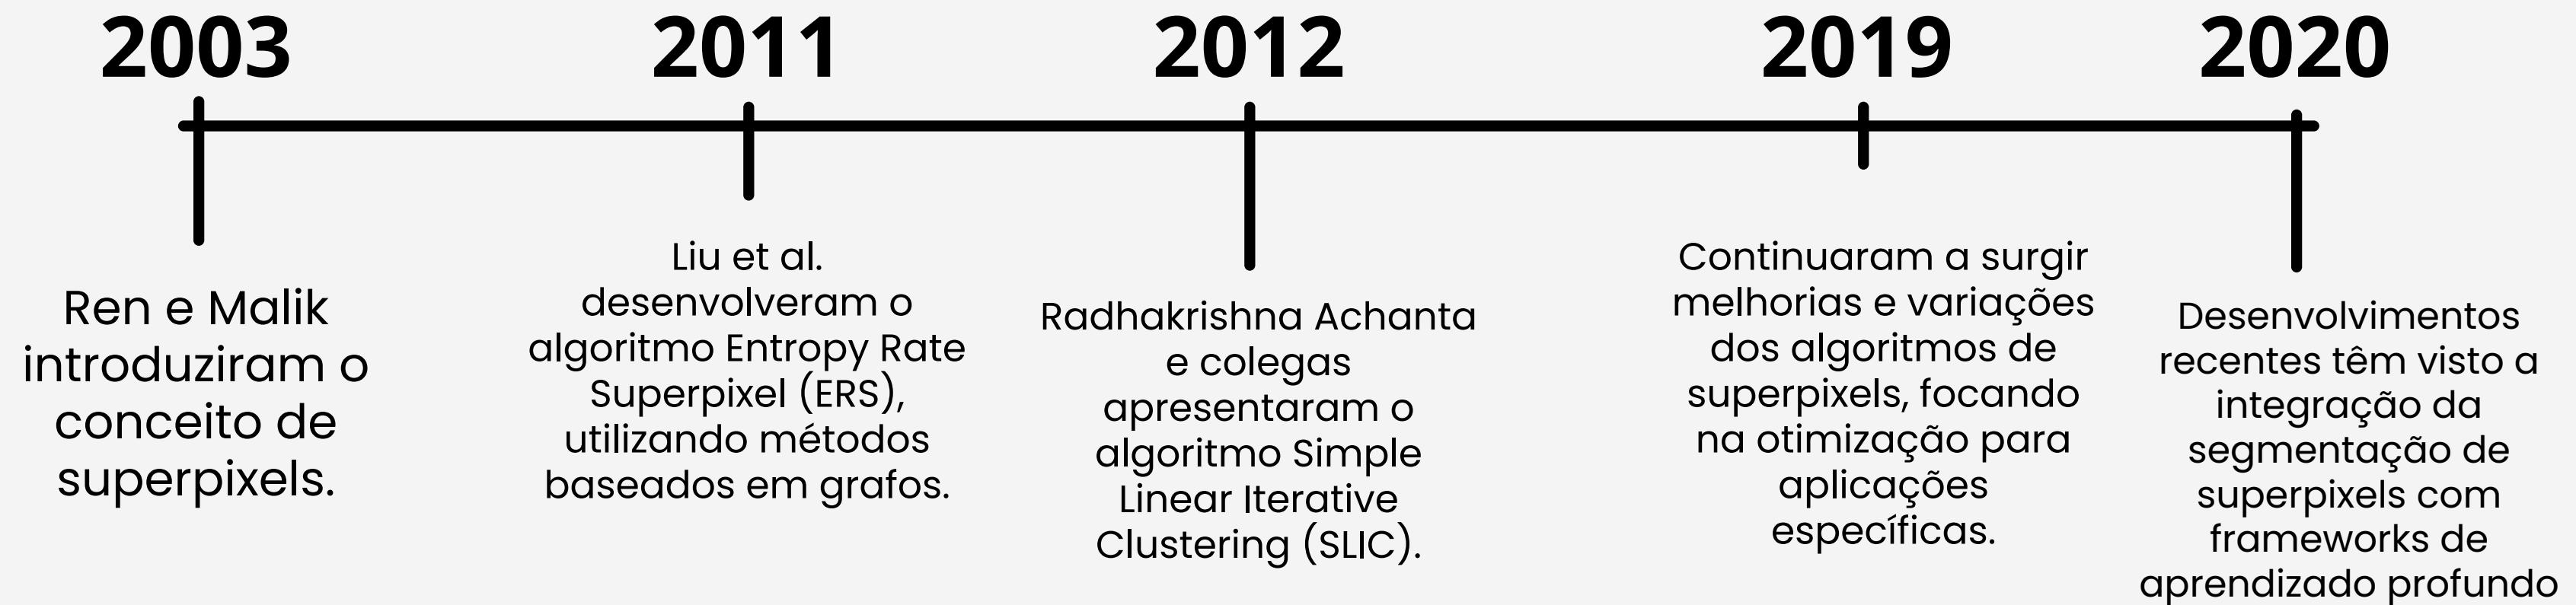
# O que são Superpixels?

Superpixels são **agrupamentos de pixels** dentro de uma imagem que **compartilham características similares**, como cor, intensidade , localização espacial, textura... Poderia ser inclusive generalizado como uma '**super segmentação**'.

Eles são empregados para **simplificar a representação de uma imagem**, tornando-a mais significativa e facilitando a análise. Ao agrupar pixels semelhantes, **reduz-se a complexidade** dos dados **sem perder informações críticas** de borda e textura.

Superpixels são vitais para a segmentação de imagens, onde precisão na delimitação de objetos e regiões é crucial. No domínio de data annotation, encontram-se **inúmeras aplicações de superpixels**, nas mais diversas variações.

# Linha do tempo



# Vantagens

Ao permitir que seja possível delimitar bordas e, consequentemente, objetos de maneira mais ‘generalista’, os Superpixels nos fornecem a capacidade de ganhar algumas novas habilidades quando falamos em aplicações de VC.

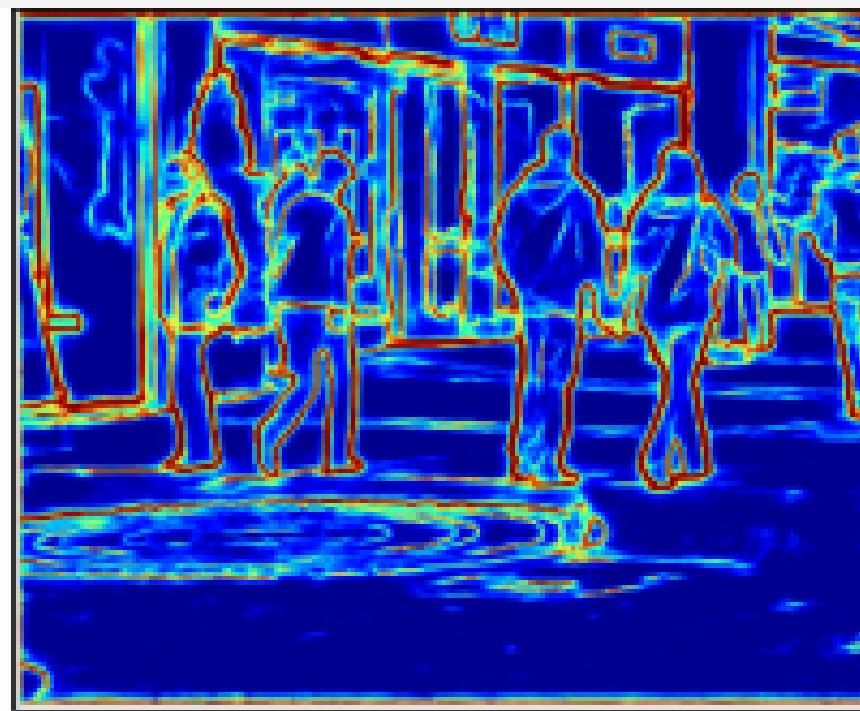
Em vez de operar em milhões de pixels individuais, o processo de segmentação pode ser **realizado em grupos de superpixels, que já são homogêneos**. Isso não apenas acelera o cálculo, mas também melhora a precisão.

Facilitam o **acompanhamento de objetos em movimento**. Com menos unidades para monitorar e uma representação mais coerente das características do objeto, o rastreamento torna-se mais robusto e menos suscetível a ruídos.

# Na prática



(a) Input

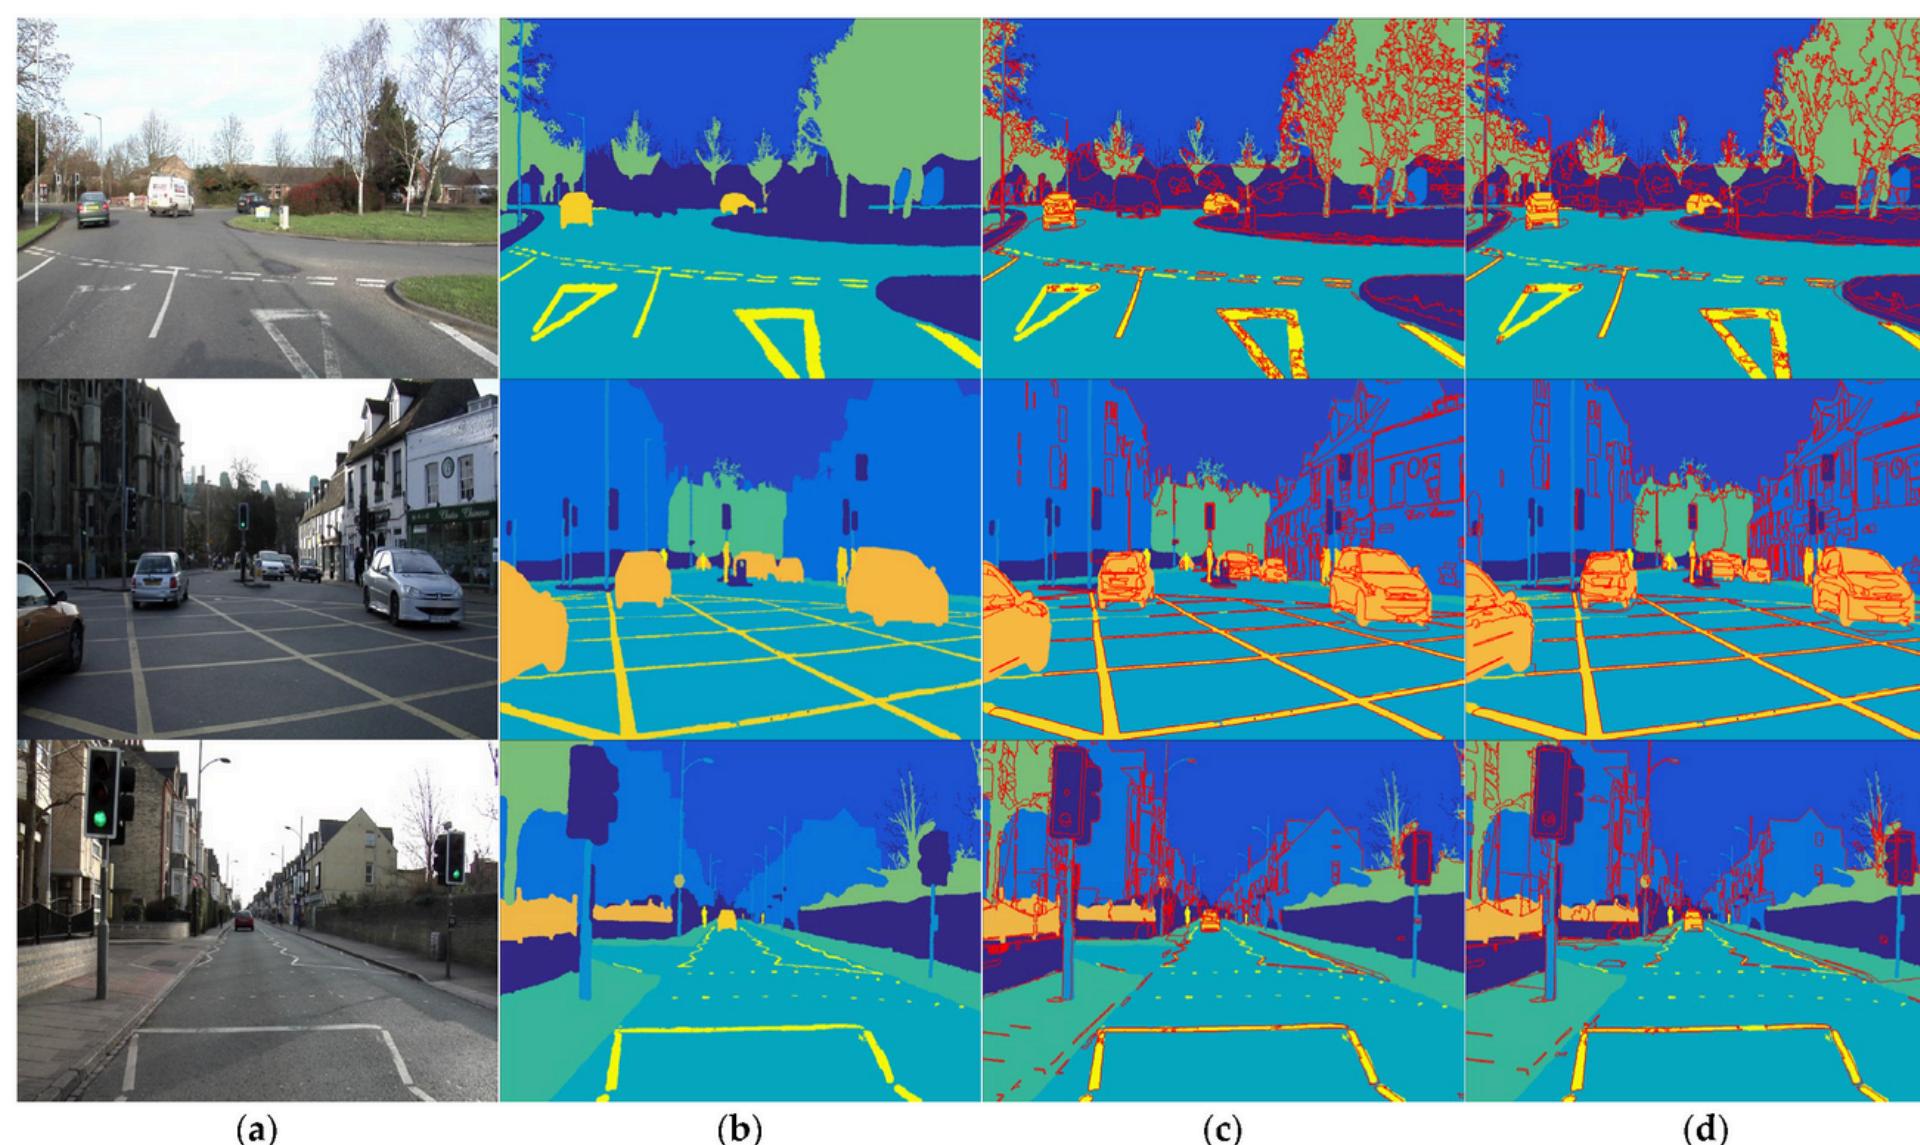


(b) Edge probability



(c) Edge sticky superpixel

# Na prática



# Algoritmo SLIC

# O que é o SLIC?

Apresentado por Radashkrina Achanta et al. em 2012, o algoritmo SLIC veio como uma forma inovadora e, no mínimo, engenhosa de se aplicar a técnica de Superpixels utilizando agrupamentos..

Seu funcionamento se baseia em uma adaptação do algoritmo de clustering k-means para trabalhar especificamente com dados de imagem. Recapitulando, o k-means trabalha com agrupamentos de pontos em torno de uma centróide ajustada à média de seus k pontos próximos.

Essa abstração permite que o SLIC processe eficientemente imagens ao agrupar pixels que são semelhantes em cor e espaço, formando superpixels que são coerentes tanto na aparência quanto na localização espacial.

# Funcionamento Algorítmico

Podemos definir o algoritmo da seguinte maneira:

**Inicialização:** O algoritmo começa com a seleção de centros de clusters que são uniformemente espaçados na imagem. Essa distribuição inicial é crucial para garantir que os superpixels cubram a imagem de maneira equilibrada.

**Associação de Pixels:** Cada pixel na imagem é então associado ao centro de cluster mais próximo com base em uma métrica que considera tanto a similaridade de cor quanto a proximidade espacial. Isso assegura que os pixels dentro de um superpixel sejam próximos e similares

**Atualização dos Centros:** Após todos os pixels serem associados a um cluster, os centros são atualizados para serem a média dos pixels que compõem cada cluster. Esse recálculo ajuda a refinar a localização dos centros para melhor representar os dados.

**Repetição:** Estes passos são repetidos iterativamente até que o algoritmo atinja a convergência.

# Funcionamento Algorítmico

Podemos definir o algoritmo da seguinte maneira:

O SLIC começa com **centros de clusters** **espaçados** pelo intervalo **S**, buscando **locais de baixo gradiente** para evitar bordas.

Cada célula é **atribuída** ao **centro de cluster mais próximo**, e a distância **D** é calculada entre os centros de clusters e as células ( $2S \times 2S$ ).

$$D = \sqrt{\left(\frac{d_c}{m}\right)^2 + \left(\frac{d_s}{S}\right)^2}$$

onde **dc** é a distância de cor (espectral), **m** é o parâmetro de compactação (dá mais peso à proximidade espacial), **ds** é a distância espacial (euclidiana), e **S** é o intervalo entre os centros de clusters iniciais.

Posteriormente, novos centros de clusters (centroides) são atualizados para os novos superpixels, e **seus valores de cor** são a média de todas as células pertencentes ao superpixel dado.

Há 2 parâmetros importantes aqui: **coeficiente de compactação m** e um **K número de Superpixels**.

# Distância Espectral

Podemos definir a distância espectral matematicamente como:

$$dc = \sqrt{\sum_{p \in B} (I(x_i, y_i, sp) - I(x_j, y_j, sp))^2}$$

onde os termos centrais são as intensidades de cor num pixel nas coordenadas x e y, dentro da banda de cor sp, somadas sobre o conjunto de bandas espectrais B. Em imagens multiespectrais, B pode incluir diversas faixas além das visíveis (como infravermelho).

A diferença é elevada ao quadrado para garantir distâncias positivas e enfatizar diferenças maiores. Por fim, a raiz quadrada serve para refazer a métrica original de escala.

# Distância Espacial

Podemos definir a distância espacial (uma velha conhecida) matematicamente como:

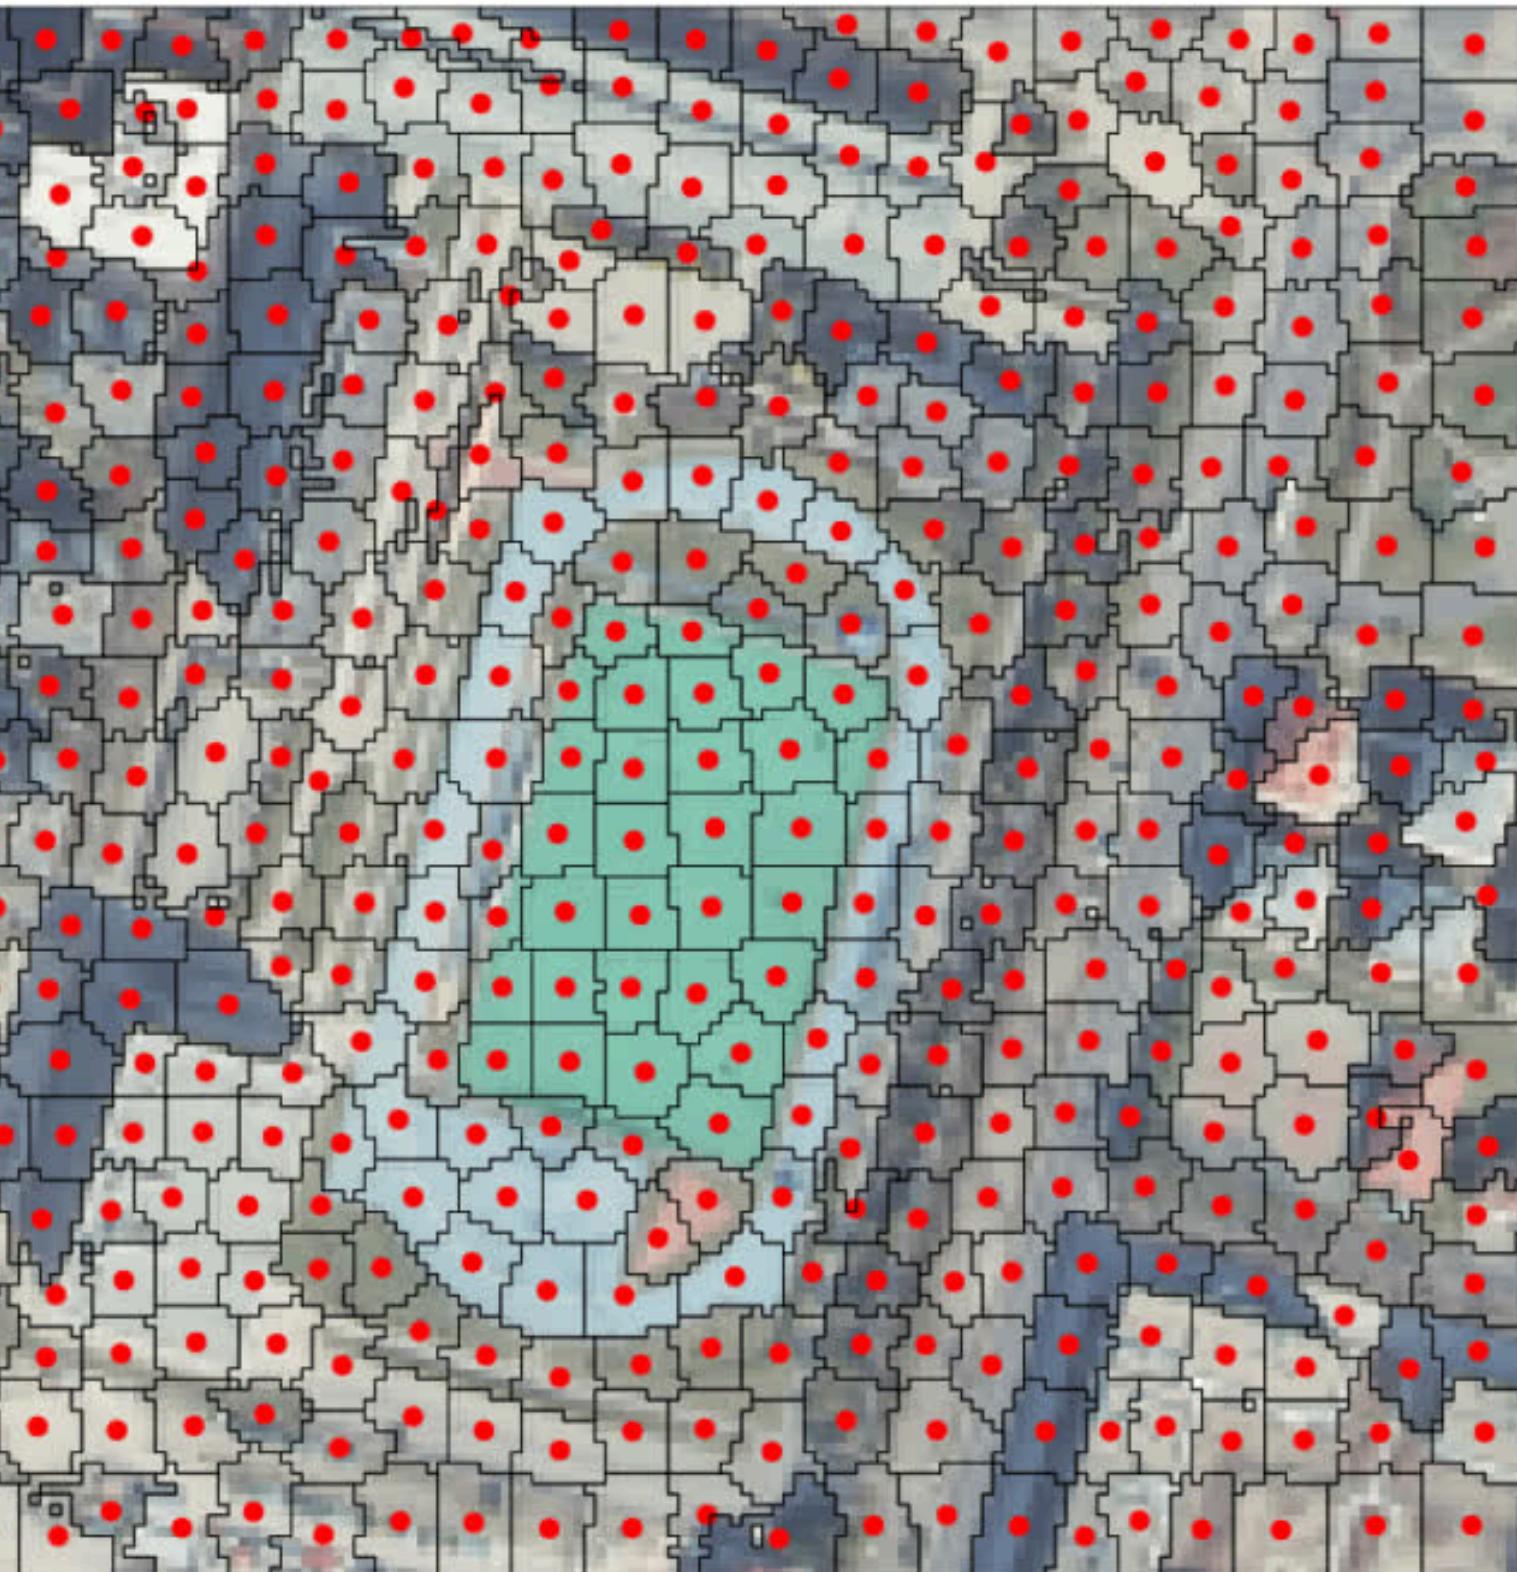
$$ds = \sqrt{(x_j - x_i)^2 + (y_j - y_i)^2}$$

onde a distância euclidiana entre um pixel  $x_i, y_i$  e um cluster  $x_j, y_j$  é calculada.

# Iteration: 6

## Algorithm 1 SLIC superpixel segmentation

```
/* Initialization */
Initialize cluster centers  $C_k = [l_k, a_k, b_k, x_k, y_k]^T$  by
sampling pixels at regular grid steps  $S$ .
Move cluster centers to the lowest gradient position in a
 $3 \times 3$  neighborhood.
Set label  $l(i) = -1$  for each pixel  $i$ .
Set distance  $d(i) = \infty$  for each pixel  $i$ .
repeat
    /* Assignment */
    for each cluster center  $C_k$  do
        for each pixel  $i$  in a  $2S \times 2S$  region around  $C_k$  do
            Compute the distance  $D$  between  $C_k$  and  $i$ .
            if  $D < d(i)$  then
                set  $d(i) = D$ 
                set  $l(i) = k$ 
            end if
        end for
    end for
    /* Update */
    Compute new cluster centers.
    Compute residual error  $E$ .
until  $E \leq \text{threshold}$ 
```



# Aplicações e Desafios

# Prós e Contras

# Balanço do SLIC

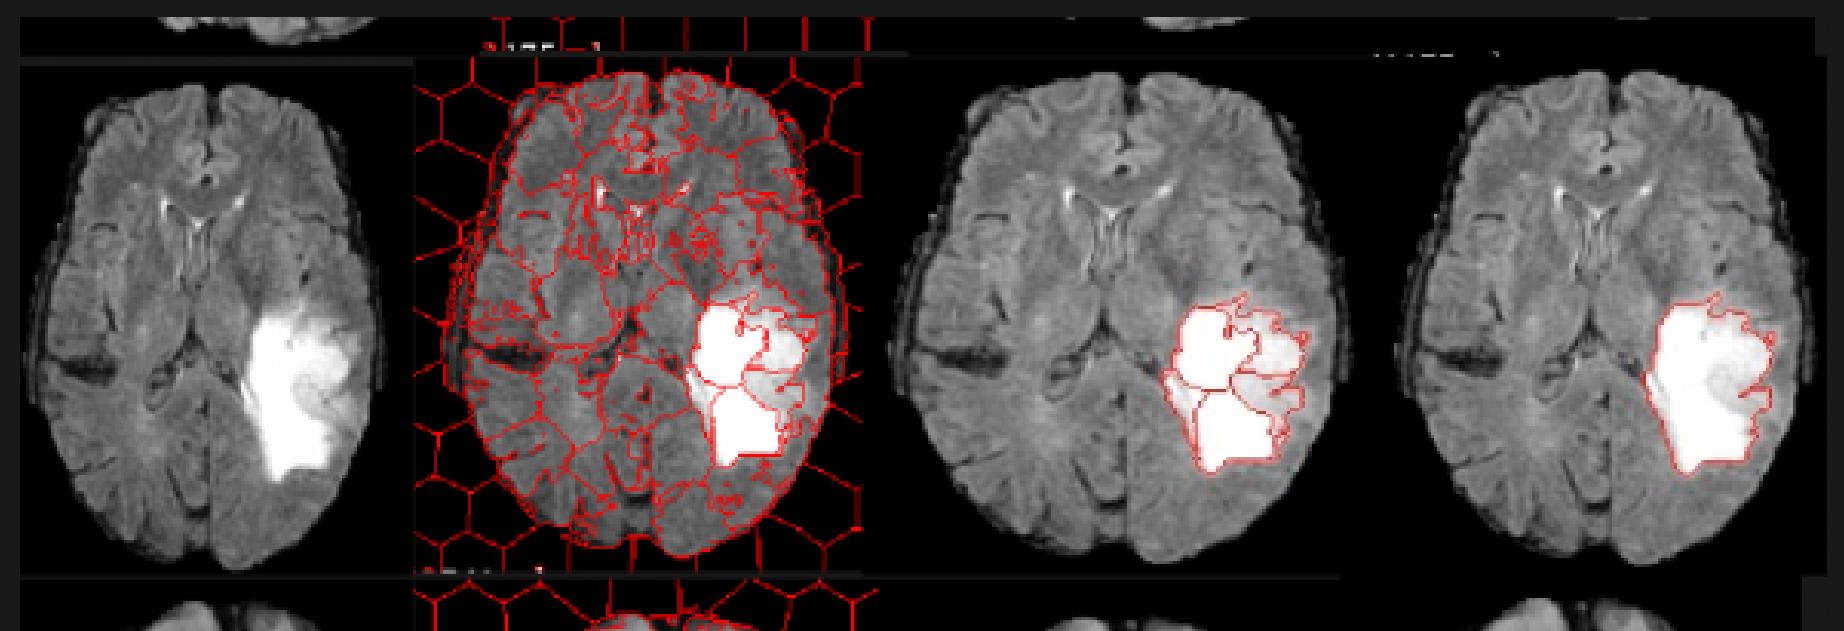
- 
- **Baixo Custo Computacional:** Comparado a outros métodos de segmentação, o SLIC é eficiente e rápido, adequado para aplicações em tempo real.
  - **Eficiência:** O algoritmo é eficiente em termos de memória e processamento, o que facilita seu uso em dispositivos com recursos limitados. Em termos de complexidade:  $O(N)$ . Como referência, K-means normal é  $O(KNI)$
  - **Adesão aos Limites dos Objetos:** SLIC tem uma capacidade notável de aderir bem aos contornos dos objetos, o que é crucial para muitas aplicações de processamento de imagem e análise visual.
  - **Sensibilidade a Parâmetros:** a escolha do número de superpixels pode drasticamente alterar a granularidade da segmentação, enquanto o parâmetro de compactação afeta a regularidade e a compactação dos superpixels.
  - **Aderência a Bordas:** apesar de o SLIC geralmente apresentar boa aderência às bordas dos objetos, ele pode falhar em imagens com bordas muito complexas ou com padrões de textura intrincados.
  - **Desempenho em Imagens com Baixo Contraste:** dificuldades em segmentar corretamente regiões de uma imagem que possuem baixo contraste, mas distintas em textura ou outra característica não colorimétrica.

# Aplicações

# Diagnóstico por Imagem

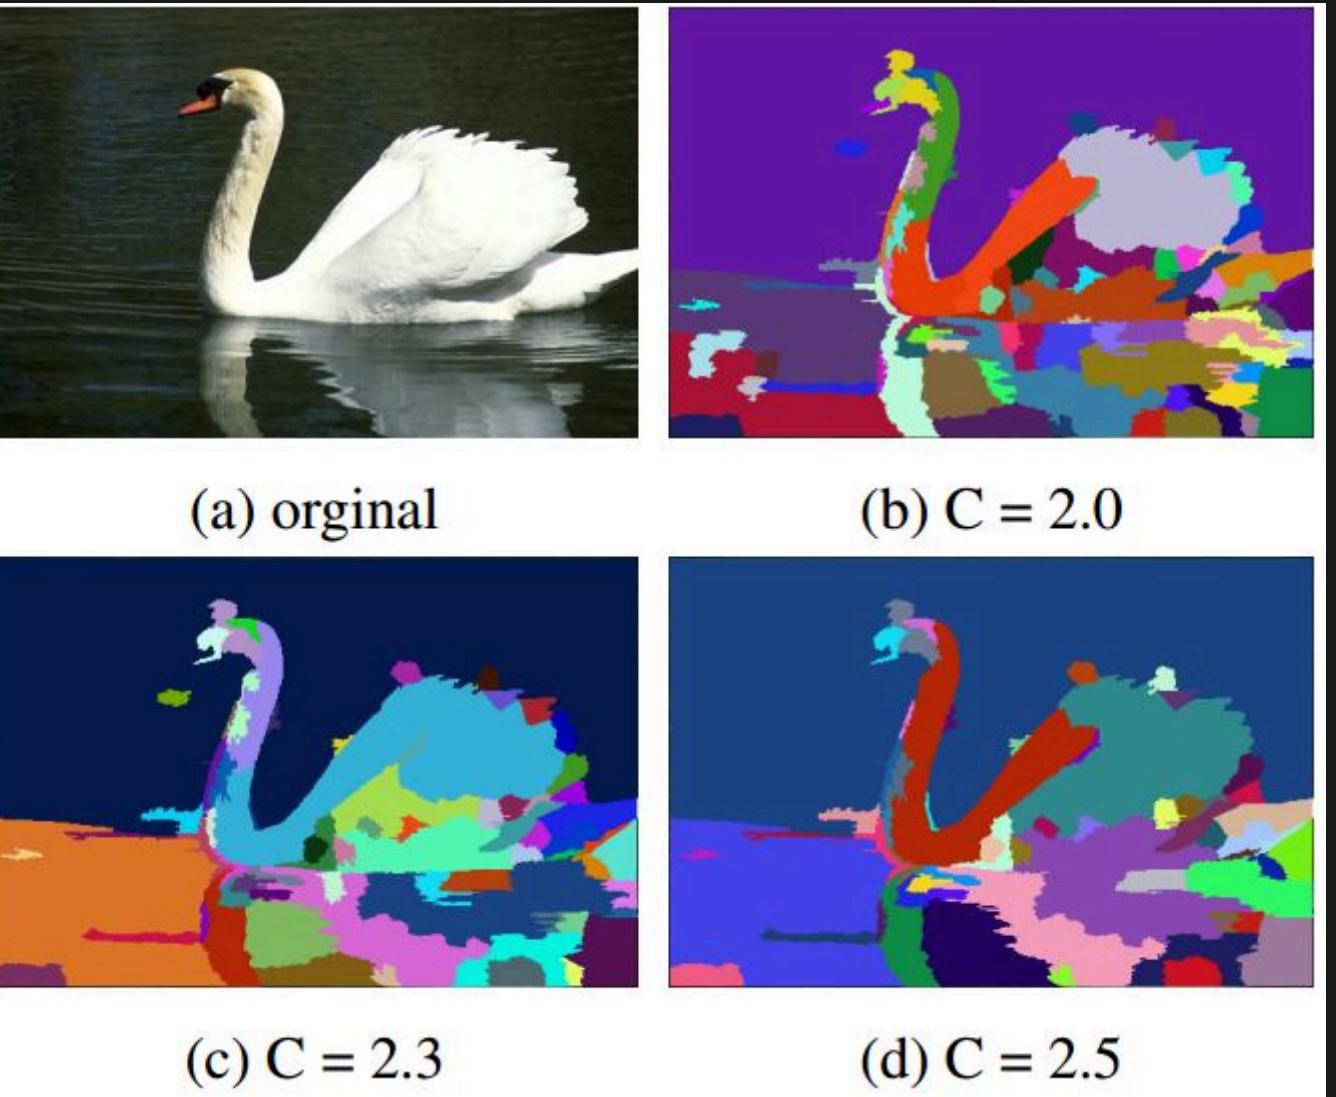
---

- No campo médico, o SLIC é usado para segmentar imagens de tomografia computadorizada (CT) e ressonância magnética (MRI), ajudando na identificação de regiões de interesse, como tumores ou outras anormalidades. A precisão na segmentação facilita diagnósticos mais acurados e planejamento de tratamentos.



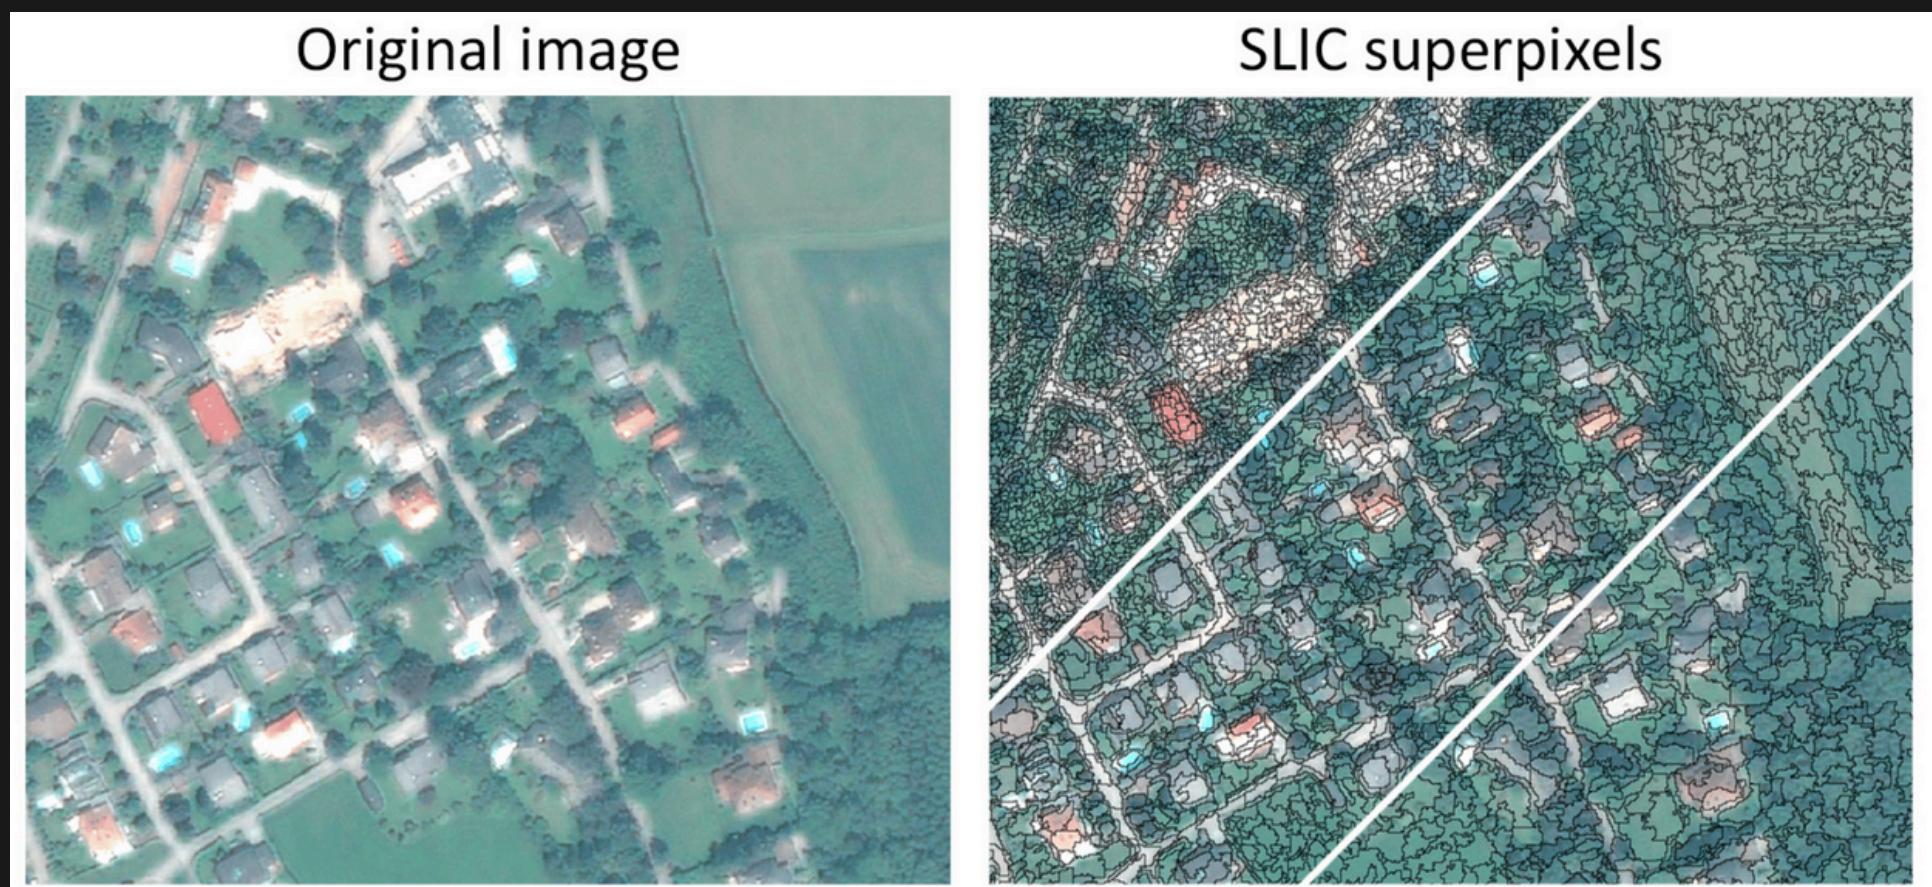
# Reconhecimento de Objetos

- Robôs utilizam o SLIC para segmentar e identificar objetos em seu campo de visão, o que é crucial para tarefas como manipulação de objetos e navegação autônoma. Os superpixels ajudam a reduzir a quantidade de dados a serem processados, aumentando a velocidade e eficiência do reconhecimento.



# Imagens de Satélite

- O SLIC é empregado na análise de imagens de satélite para segmentar regiões geográficas, facilitando a detecção de mudanças no uso da terra, monitoramento ambiental e planejamento urbano. A capacidade de segmentar eficientemente grandes áreas ajuda os analistas a obter insights mais rápidos e precisos.



# Sistemas de Vigilância

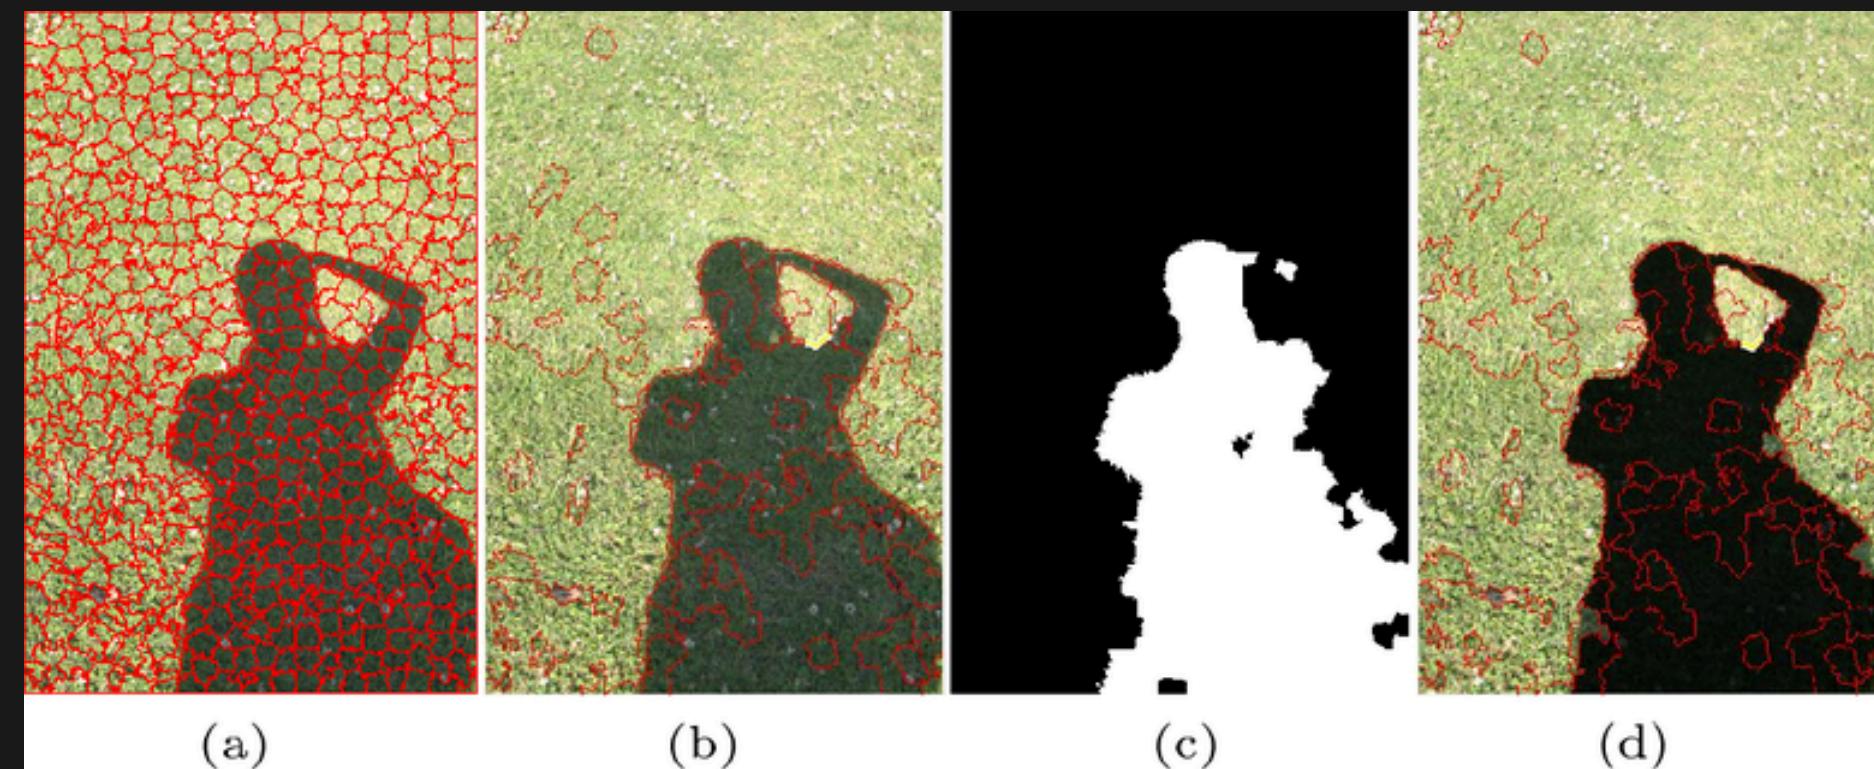
---

- Em sistemas de vigilância, o SLIC é usado para segmentar e rastrear objetos em movimento, como veículos ou pessoas. Isso permite uma monitorização mais eficiente e pode ajudar na detecção automática de atividades suspeitas ou anormais.



# Melhoramento em Edição de Fotos

- Em aplicações de edição de fotos, o SLIC pode ser utilizado para realizar seleções inteligentes de regiões de uma imagem, facilitando a aplicação de efeitos, ajustes de cor ou blur seletivo. Isso proporciona aos editores um controle mais refinado sobre o processo de edição.



# Conclusões

# O que se pode concluir

## Definição do Superpixel e SLIC

Uma técnica inovadora que transformou o campo da visão computacional. Com sua habilidade em agrupar pixels semelhantes de forma eficaz, o SLIC simplifica a complexidade das imagens, permitindo uma análise mais rápida e eficiente.

## Aplicações Inúmeras (e vitais)

Há diversas aplicações práticas que vão desde a segmentação de imagens médicas até o reconhecimento de objetos em robótica, demonstrando a versatilidade e o impacto significativo dessa técnica.

## O Futuro

Com o advento da IA, a técnica de superpixels está posicionada para desempenhar um papel ainda mais crucial na visão computacional. O futuro provável verá a integração dos superpixels com aprendizado profundo e redes neurais, potencializando análises mais sofisticadas e automatizadas em diversas áreas. Além disso, espera-se que novas pesquisas expandam a aplicabilidade dos superpixels para além das imagens tradicionais, explorando dados multidimensionais e contribuindo para avanços significativos em análise sensorial e interpretação ambiental.



# DÚVIDAS?

# Referências

- SLIC Superpixels Compared to State-of-the-art Superpixel Methods (Arachanta Radhakrishna et al.)
- Accelerated gSLIC for Superpixel Generation used in Object Segmentation (Robert Birkus)
- A method for universal superpixels-based regionalization (Jakub Nowosad et al.)
- Learning a Classification Model for Segmentation (Xiaofeng Ren and Jitedra Malik)



**OBRIGADO E HORA DA  
DEMO!**